td

September 17, 2023

1 Deux problématiques possibles :

Il arrive qu'au moment des inspections, une situation indépendante de la volonté de l'entreprise puisse impacter négativement les résultats obtenus injustements (comme des cas d'épidémies ou infestations locales). Il serait alors intêressant de pouvoir détecter ces évènements, afin de permettre leurs analyses et signalements sans pour autant dégrader la réputation d'une entreprise.

Dans l'optique de garantir que les inspections sont le plus fiable possible, nous allons chercher à détecter si certains facteurs, potentiellement discriminants, peuvent biaiser les résultats.

1.0.1 Problématique 1 : "Clusters épidémiques"

Avec en tête que nous cherchons à identifier les sites ayant des reviews négatives ayant potentiellement une cause indépendante de la volonté de l'entreprise, nous supposons qu'à partir de la date d'insepction et de la localisation des locaux de l'entreprise, il serait possible, grâce à un modèle de clustering type Knn : - d'identifier les inspections ayant eu lieu dans un intervalle de temps et de lieu proches ayant résultés en un état désatisfaisant, ce qui pourrait indiquer une cause commune ponctuelle qui mériterait d'être analysée. - d'identfier si certains lieux géographiques sont potentiellement plus insalubres et nécessiteraient une intervention ou signalement commun.

1.0.2 Problématique 2 : "Biais malicieux"

Avec en tête que nous cherchons à identifier des biais qui pourraient impacter, volontairement ou non, positivement ou négativement, les résultats des inspections, il serait possible, grâce à un modèle de régression : - De vérifier si tous les paramètres sont traités équitablements. - De voir s'il existe une cause commune à un résultat positif ou négatif d'une inspection, qui ne relève pas des critères évualués.

Pour pouvoir étudier cette problématique avec davantage de précision, il faudrait ajouter de la donnée aux rapports. Ces données pourraient venir de sources publiques (API Google Maps, infos publiques liées au SIRET…) ou être ajoutées au processus métier (commentaires ou détails de notes d'évaluation…)

[98]:
```
# Packages génériques
import sys
import os
import importlib
```

```
import numpy as np  # Calcul numérique
import pandas as pd  # Données au format tabulaire, transformation et analyse de données

# Graphiques
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib as mpl  # pour afficher le numéro de version logicielle
from sklearn.cluster import KMeans
from sklearn.preprocessing import LabelEncoder
from datetime import datetime
```

[64]:
```
dataset = "export_alimconfiance.csv"

dataset = pd.read_csv(dataset)

dataset.head()
```

[64]:

	APP_Libelle_etablissement	SIRET	Adresse_2_UA	Code_postal	Libelle_commune	Numero_inspection	Date_inspection	APP_Libelle_activite_etablissement	Synthese_eval_sanit	Agrement	geores	filtre ods_type_activite
0	SARL AUBERGE DU DOUBLE SIX	30121048000010	24 PL GENERAL LECLERC	80220	GAMACHES	16793484	2023-04-25T02:00:00+02:00	Restaurant	Satisfaisant	NaN	49.985274, 1.561386	
1	MONSIEUR PHILIPPE MARIOTTE	31084873400029	286 RUE DU CENTRE	74260	LES GETS	16740394	2023-02-23T01:00:00+01:00	Restaurant	Satisfaisant	NaN	46.15861, 6.677963	
2	NATURALIA (NATURALIA FRANCE)	30247464801894	36 RUE EUGENE EICHENBERGER	92800	PUTEAUX	16611978	2022-10-04T02:00:00+02:00	Alimentation générale	Satisfaisant	NaN	48.881317, 2.23746	
3	SUPER-U (COLOMBELLES DISTRIBUTION)	30122377200031	RD 403	14460	COLOMBELLES	16787460	2023-04-20T02:00:00+02:00	Rayon boucherie-charcuterie	Très satisfaisant	NaN	NaN	
4	FRANPRIX (SOC DISTRIBUTION SODISCO SARL)	33427109500013	4, PLACE DU MOUSTIER	92210	SAINT CLOUD	16748988	2023-03-08T01:00:00+01:00	Alimentation générale	A améliorer	NaN	48.844091, 2.219818	

```
0                   Restaurant            Autres
1                   Restaurant            Autres
2        Alimentation générale            Autres
3  Rayon boucherie-charcuterie            Autres
4        Alimentation générale            Autres
```

[65]:
```
# Remove useless columns
COLUMNS_NON_HIERAR = ["APP_Libelle_etablissement", "Adresse_2_UA",␣
 ↪"Code_postal", "Libelle_commune", "APP_Libelle_activite_etablissement",␣
 ↪"geores", "filtre", "ods_type_activite"]
COLUMNS_HIERRAR = ["Synthese_eval_sanit", "Date_inspection"]
dataset = dataset[COLUMNS_NON_HIERAR + COLUMNS_HIERRAR]

dataset.describe()
```

[65]:
```
       APP_Libelle_etablissement Adresse_2_UA Code_postal
count                      32719        32292       32720  \
unique                     25744        27101        4989
top      ECOLE PRIMAIRE PUBLIQUE     LE BOURG       75015
freq                         162           91         557

                 Libelle_commune APP_Libelle_activite_etablissement
count                      32720                             32720  \
unique                      8460                               149
top     Paris 15e  Arrondissement                        Restaurant
freq                         536                             11653

               geores      filtre ods_type_activite Synthese_eval_sanit
count           31961       24086             32720               32720  \
unique          26914          94                 7                   4
top     48.859, 2.347  Restaurant            Autres        Satisfaisant
freq               50       11653             24737               17976

                 Date_inspection
count                      32720
unique                       299
top     2023-04-04T02:00:00+02:00
freq                         251
```

1.0.3 PB 1 Hypothèse 2

Analyse et restriction des données

Puisque nous cherchons à identifier les clusters insalubres, nous allons resteindre notre sélection de données aux évalutions insatisfaisantes.

[72]:
```
COLUMNS_OF_INTEREST = ["Synthese_eval_sanit", "geores"]
```

```
data = dataset.copy() # MAKE A CLEAN SLATE COPY FOR THIS SEGMENT


# SEARCH DATA KEYS TO KEEP
for name, group_data in data.groupby("Synthese_eval_sanit"):
    print(name)
```

```
A améliorer
A corriger de manière urgente
Satisfaisant
Très satisfaisant
```

- Data conservée : “A améliorer” + “A corriger de manière urgente”. Nous n’avons pas besoin de distinguer l’un de l’autre, alors nous ne nourrirons pas cette information au modèle.

Egalement, afin de simplifier la visualisation des résultats, nous allons chercher à cantonner nos résultats à la France métropolitaine. Pour cela, nous n’allons conserver que la donnée d’une latitude supérieure à 30.

[75]:
```
# DROP USELESS COLUMNS, RESTRICT DATA

df = data[COLUMNS_OF_INTEREST].dropna()

# TRANSFORM "geores" BY SPLITTING IT IN "longitude", "latitude"
df[['lat', 'lng']] = df['geores'].str.split(', ', expand=True).astype(float)
df = df.drop('geores', axis=1)

# REMOVE USELESS ROWS
df = df[(df['Synthese_eval_sanit'] == 'A améliorer') |␣
 ↪(df['Synthese_eval_sanit'] == 'A corriger de manière urgente')]
df = df[df['lat'] > 30]

df.describe()
```

[75]:

	lat	lng
count	1940.000000	1940.000000
mean	47.293139	2.527574
std	2.193290	2.272321
min	41.938073	-4.759437
25%	45.450000	1.615195
50%	48.334387	2.351357
75%	48.885000	3.583333
max	50.961239	9.465493

[76]:
```
# Visualise and analyse data
```

```
plt.scatter(df['lng'], df['lat'], s=2)

plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title('Nuage de points')

plt.show()
```

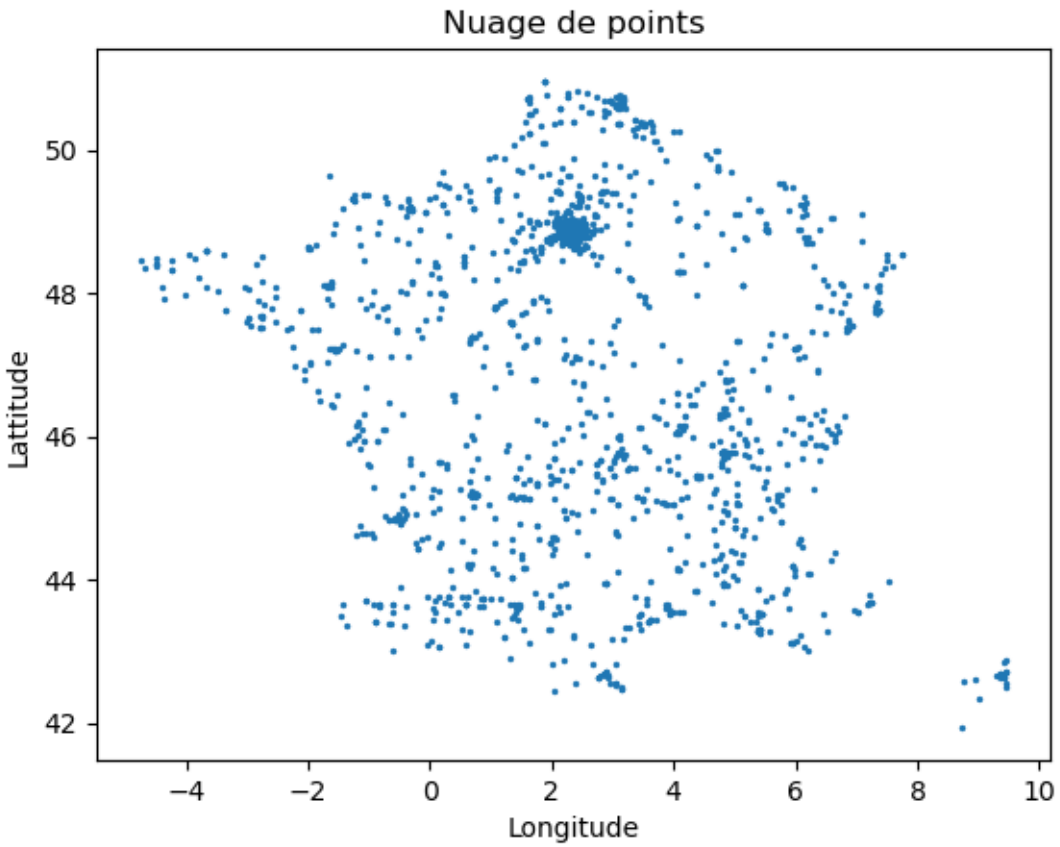

Nous remarquons un gros problème immédiatement : il y a une grande concentration de données en région parisienne par rapport au reste de la France. Nous allons, dans un premier temps, chercher à l'ignorer, et si cela prouve être un trop gros problème, nous chercherons un traitement approprié.

1.0.4 Première version : Modèle avec 800 clusters, 10 inspections insatisfaisantes pour qu'un cluster soit considéré comme "insalubre"

[77]:
```
# CREATE INITIAL MODEL AND EVALUATE

df_cluster = df.copy()
```

```
# COUNT OF CLUSTER WANTED
k = 800

# CREATE KMEANS MODEL
kmeans = KMeans(n_clusters=k, n_init="auto")

# FIT UNSUPERVISED MODEL
kmeans.fit(df_cluster[['lat', 'lng']])

# SAVE LABELS GENERATED BY MODEL
labels = kmeans.labels_

# ADD LABELS TO THE DATAFRAME
df_cluster['Cluster'] = labels

df_cluster.head()
```

[77]:

	Synthese_eval_sanit	lat	lng	Cluster
4	A améliorer	48.844091	2.219818	674
6	A améliorer	48.448928	-4.249809	271
19	A améliorer	47.807466	1.078596	509
20	A améliorer	45.057360	5.770684	771
21	A améliorer	48.794437	2.155045	333

[78]:
```
plt.scatter(df_cluster['lng'], df_cluster['lat'], c=labels, cmap='viridis', s=3)
# plt.scatter(kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1],␣
  ↪s=2, label='Centroids')
plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title(f'K-Means Clustering (k={k})')
plt.legend()
plt.show()
```

```
No artists with labels found to put in legend.  Note that artists whose label
start with an underscore are ignored when legend() is called with no argument.
```

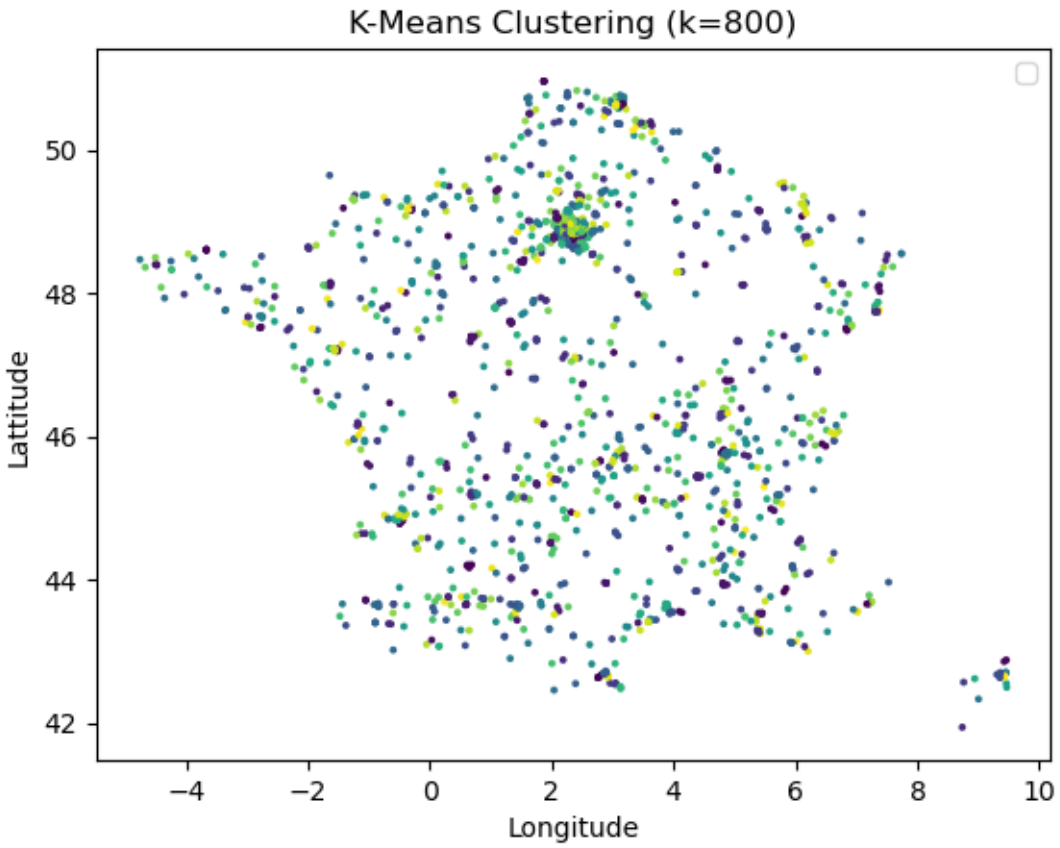

Une fois les clusters identifiés par le modèle, nous n'allons conserver que les clusters qui présentent une concentration anormale de lieu insatisfaisants.

[79]:
```
# ONLY KEEP CLUSTERS WITH A SIZE BIGGER THAN THE VARIABLE DEFINED

max_size = 10

clusters = df_cluster.groupby('Cluster').count()[df_cluster.groupby('Cluster').
 ↪count()['lat'] > max_size].index.tolist()
len(clusters)
```

[79]: 24

[80]:
```
# COLOR CODING FOR VISUALISATION
def set_cluster(row):
    if row['Cluster'] in clusters:
        return 20
    else:
        return 1
```

```
df_cluster['Color'] = df_cluster.apply(set_cluster, axis=1)

plt.scatter(df_cluster['lng'], df_cluster['lat'], s=df_cluster['Color'],␣
 ↪c=df_cluster['Color'])

# ADD LABELS AND A TITLE
plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title('Nuage de points')

# DISPLAY GRAPH
plt.show()
```

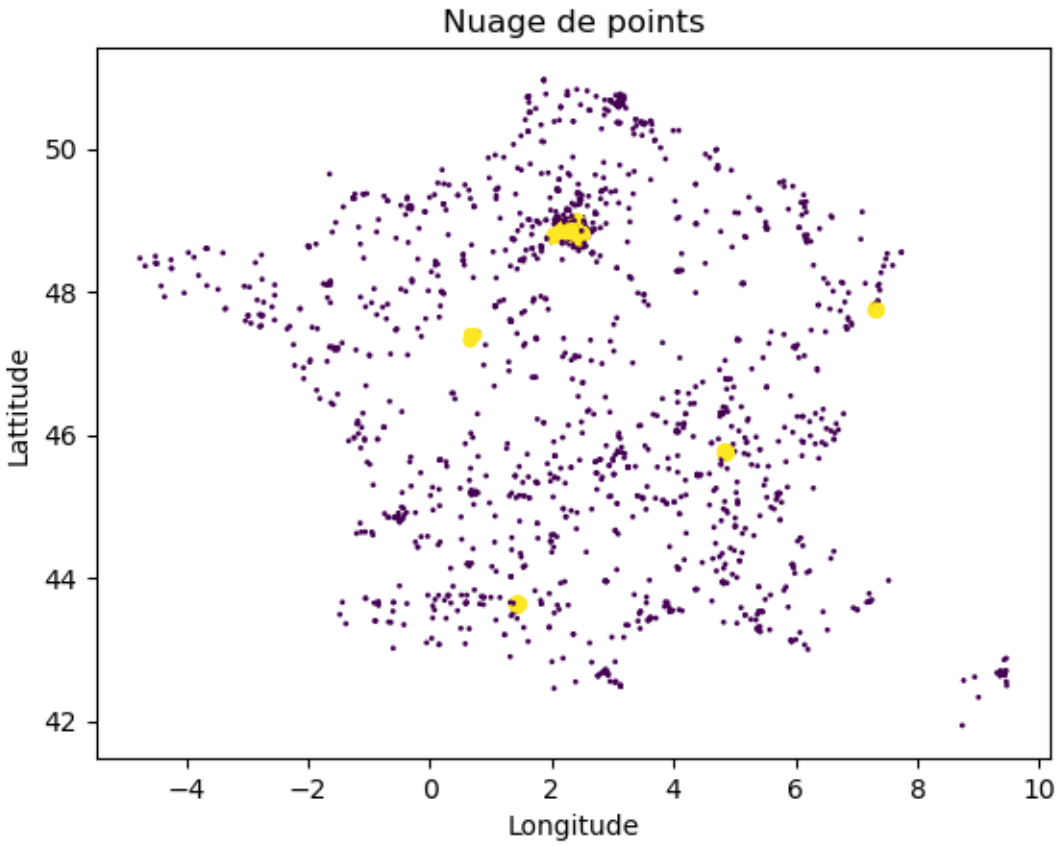

Le dataset comprends une grande concentration d'inspection en région parisienne, d'où la présence d'un grand nombre de clusters sur ce lieu. Nous allons donc essayer d'améliorer le modèle afin d'obtenir moins de clusters en région parisienne et potentiellement davantage de clusters en dehors de celle-ci. Pour cela, nous allons réduire le nombre le cluster, ce qui aura pour effet d'augmenter leur taille.

1.0.5 Deuxieme version : 200 Clusters

[81]:
```
# CREATE INITIAL MODEL AND EVALUATE

df_cluster = df.copy()

# COUNT OF CLUSTER WANTED
k = 200

# CREATE KMEANS MODEL
kmeans = KMeans(n_clusters=k, n_init="auto")

# FIT UNSUPERVISED MODEL
kmeans.fit(df_cluster[['lat', 'lng']])

# SAVE LABELS GENERATED BY MODEL
labels = kmeans.labels_

# ADD LABELS TO THE DATAFRAME
df_cluster['Cluster'] = labels

df_cluster.head()
```

[81]:

	Synthese_eval_sanit	lat	lng	Cluster
4	A améliorer	48.844091	2.219818	162
6	A améliorer	48.448928	-4.249809	192
19	A améliorer	47.807466	1.078596	97
20	A améliorer	45.057360	5.770684	47
21	A améliorer	48.794437	2.155045	64

[83]:
```
# VISUALIZE RESULTS
plt.scatter(df_cluster['lng'], df_cluster['lat'], c=labels, cmap='viridis', s=3)
plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title(f'K-Means Clustering (k={k})')
plt.legend()
plt.show()
```

```
No artists with labels found to put in legend.  Note that artists whose label
start with an underscore are ignored when legend() is called with no argument.
```

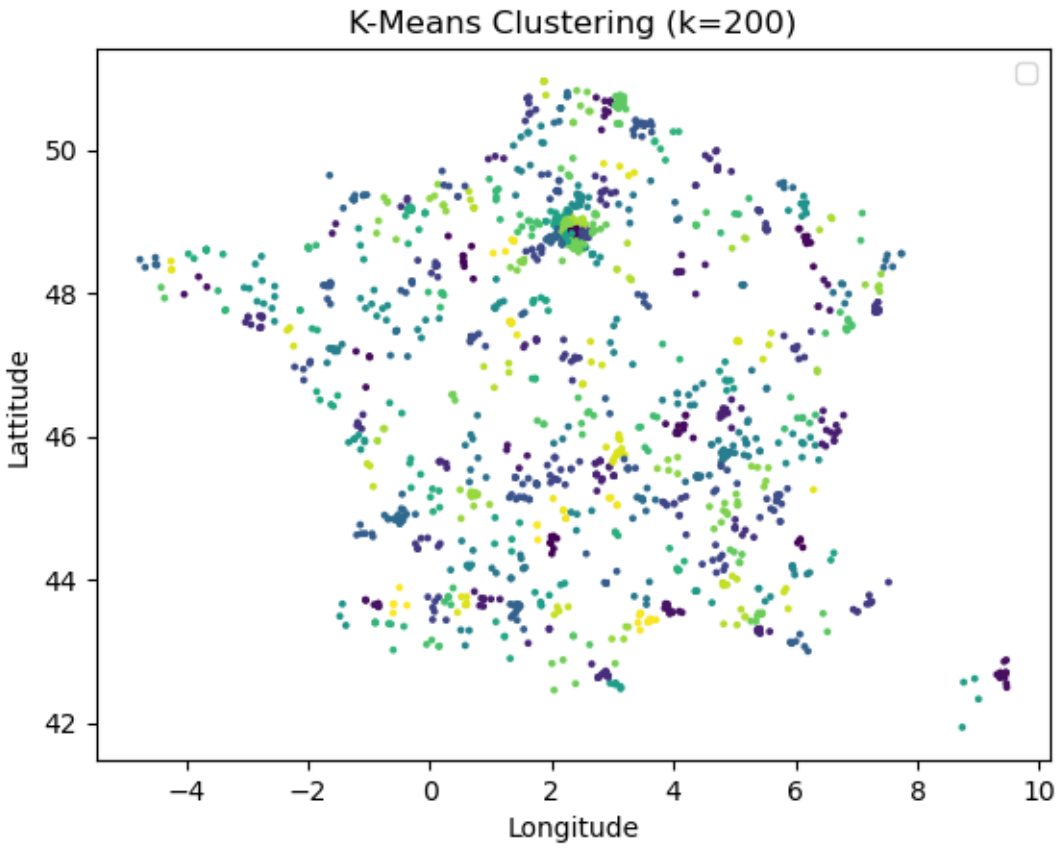

Comme le nombre de cluster a été réduit, nous allons augmenter la densité minimale pour qu'un cluster soit conservé

[84]:
```
max_size = 15

clusters = df_cluster.groupby('Cluster').count()[df_cluster.groupby('Cluster').
 ↪count()['lat'] > 15].index.tolist()
len(clusters)
```

[84]: 18

[86]:
```
# COLOR AND SIZE CODING FOR VISUALISATION
def set_size(row):
    if row['Cluster'] in clusters:
        return 20
    else:
        return 1

def set_color(row):
    if row['Cluster'] in clusters:
```

```
        return row['Cluster']
    else:
        return 0


df_cluster['Size'] = df_cluster.apply(set_size, axis=1)
df_cluster['Color'] = df_cluster.apply(set_color, axis=1)

plt.scatter(df_cluster['lng'], df_cluster['lat'], s=df_cluster['Size'],␣
 ↪c=df_cluster['Color'], marker="+")

plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title('Nuage de points')

plt.show()
```

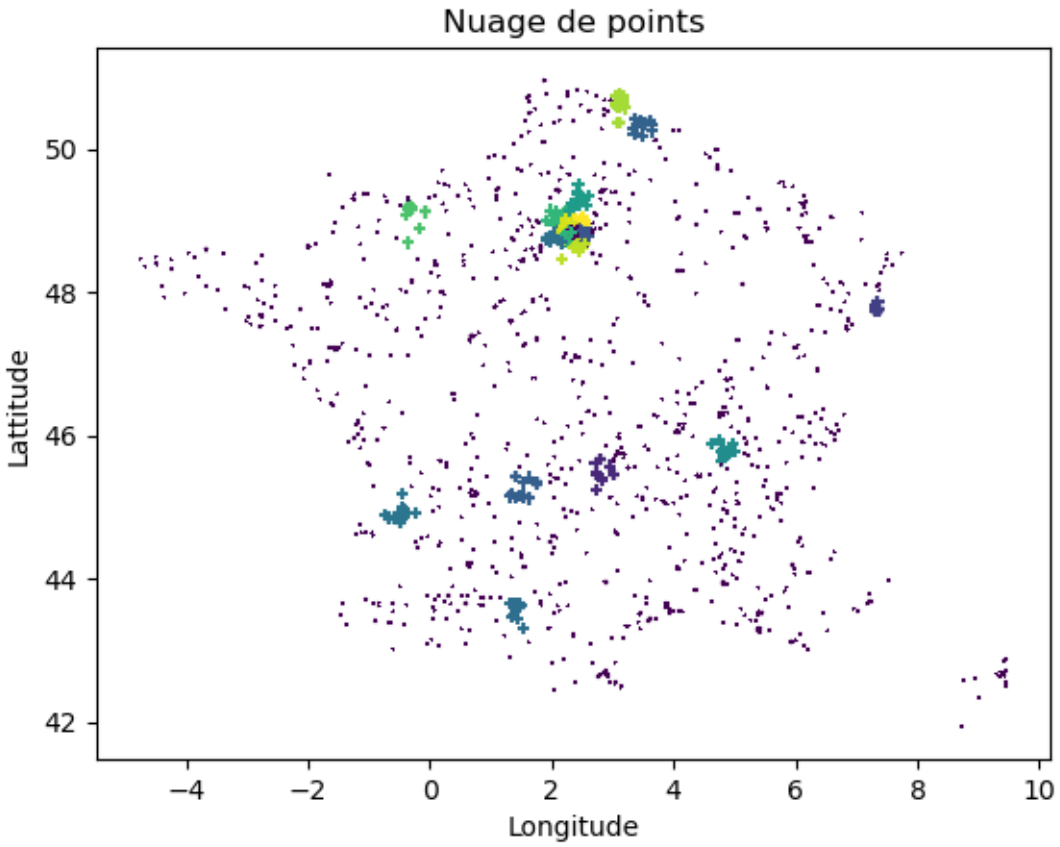

Malgré une amélioration du nombre de clusters hors de Paris, il y a toujours un grand nombre de ceux-ci dans le bassin de la capitale. Nous allons donc chercher à ajouter la région au modèle, afin qu'il puisse grouper un plus grand nombre de points de Paris

dans un seul cluster.

1.0.6 Version 3 : Ajout du libellé de région

[90]:
```
# Clean data is needed
COLUMNS_OF_INTEREST = ["Synthese_eval_sanit", "geores", "Libelle_commune"]

# Repeat data selection of Version 1 and 2
df = dataset[COLUMNS_OF_INTEREST].dropna()
df[['lat', 'lng']] = df['geores'].str.split(', ', expand=True).astype(float)
df = df.drop('geores', axis=1)
df = df[(df['Synthese_eval_sanit'] == 'A améliorer') |␣
 ↪(df['Synthese_eval_sanit'] == 'A corriger de manière urgente')]
df = df[df['lat'] > 30]

# Add Region to the final dataframe
label_encoder = LabelEncoder()
df['Libelle_commune'] = label_encoder.fit_transform(df['Libelle_commune'])

df.describe()
```

[90]:

	Libelle_commune	lat	lng
count	1940.000000	1940.000000	1940.000000
mean	597.109278	47.293139	2.527574
std	327.342837	2.193290	2.272321
min	0.000000	41.938073	-4.759437
25%	311.750000	45.450000	1.615195
50%	655.000000	48.334387	2.351357
75%	844.250000	48.885000	3.583333
max	1156.000000	50.961239	9.465493

[92]:
```
# CREATE INITIAL MODEL AND EVALUATE

df_cluster = df.copy()

# COUNT OF CLUSTER WANTED
k = 200

# CREATE KMEANS MODEL
kmeans = KMeans(n_clusters=k, n_init="auto")

# FIT UNSUPERVISED MODEL
kmeans.fit(df_cluster[['lat', 'lng', 'Libelle_commune']])

# SAVE LABELS GENERATED BY MODEL
labels = kmeans.labels_
```

```
# ADD LABELS TO THE DATAFRAME
df_cluster['Cluster'] = labels

df_cluster.head()
```

[92]:

	Synthese_eval_sanit	Libelle_commune	lat	lng	Cluster
4	A améliorer	878	48.844091	2.219818	0
6	A améliorer	451	48.448928	-4.249809	89
19	A améliorer	881	47.807466	1.078596	188
20	A améliorer	1066	45.057360	5.770684	4
21	A améliorer	1061	48.794437	2.155045	76

[93]:
```
# VISUALIZE RESULTS
plt.scatter(df_cluster['lng'], df_cluster['lat'], c=labels, cmap='viridis', s=3)
# plt.scatter(kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1],␣
  ↪s=2, label='Centroids')
plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title(f'K-Means Clustering (k={k})')
plt.legend()
plt.show()
```

```
No artists with labels found to put in legend.  Note that artists whose label
start with an underscore are ignored when legend() is called with no argument.
```

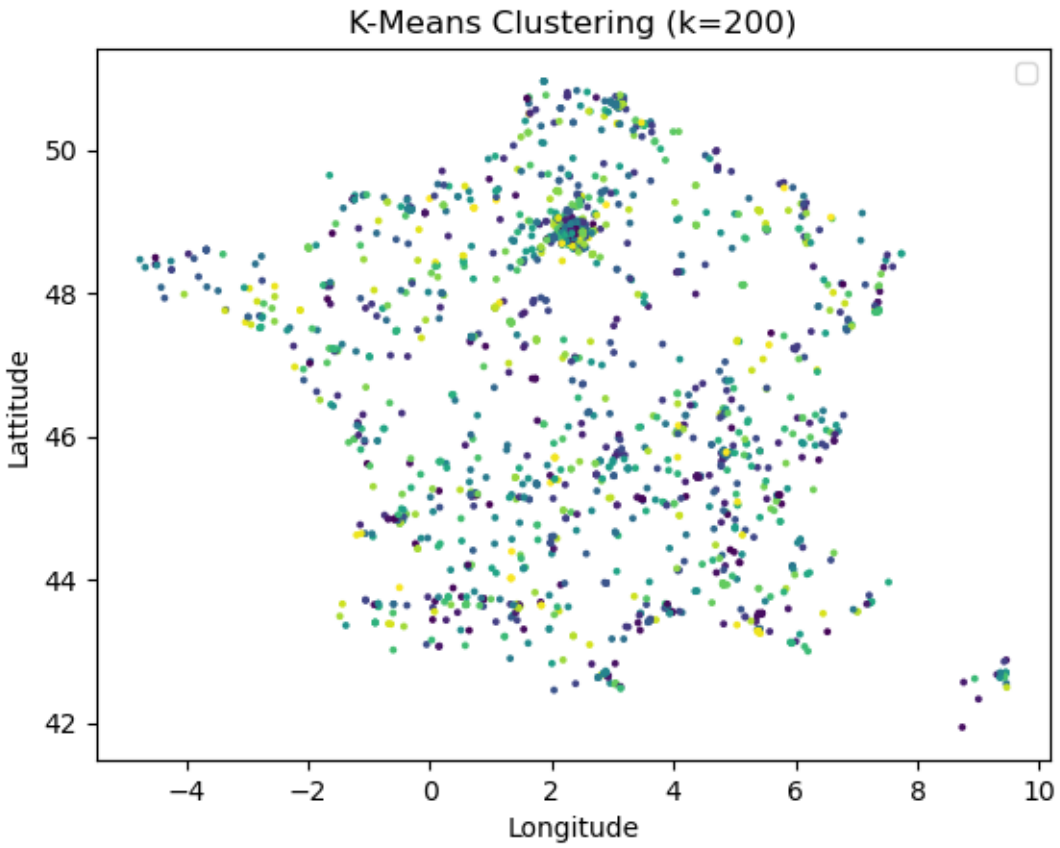

[94]:
```
max_size = 15

clusters = df_cluster.groupby('Cluster').count()[df_cluster.groupby('Cluster').
 ↪count()['lat'] > 15].index.tolist()
len(clusters)
```

[94]: 15

[95]:
```
# COLOR AND SIZE CODING FOR VISUALISATION
def set_size(row):
    if row['Cluster'] in clusters:
        return 20
    else:
        return 1

def set_color(row):
    if row['Cluster'] in clusters:
        return row['Cluster']
    else:
        return 0
```

```
df_cluster['Size'] = df_cluster.apply(set_size, axis=1)
df_cluster['Color'] = df_cluster.apply(set_color, axis=1)

plt.scatter(df_cluster['lng'], df_cluster['lat'], s=df_cluster['Size'],␣
 ↪c=df_cluster['Size'])

plt.xlabel('Longitude')
plt.ylabel('Lattitude')
plt.title('Nuage de points')

plt.show()
```

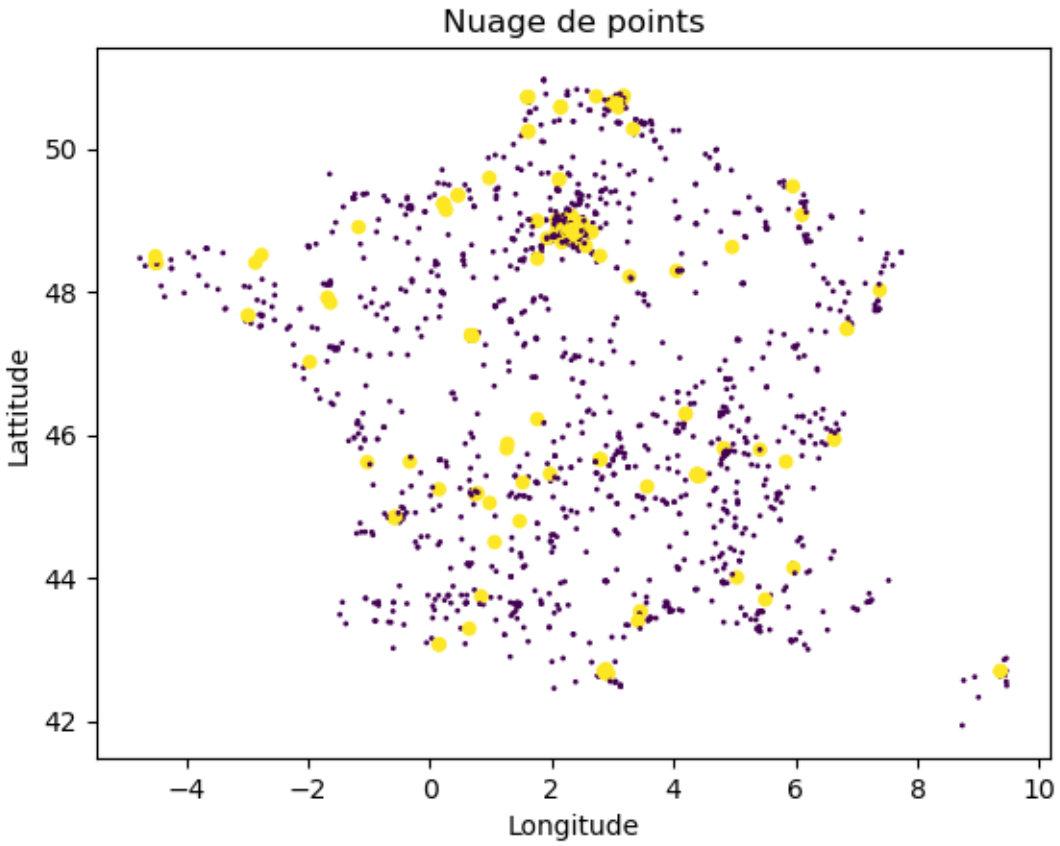

Encore une plutot nette amélioration du nombre de clusters et de leur répartition, on note qu'il y a toujours un nombre important de clusters sur Paris. Il serait peut être possible d'isoler le bassin parisien et le traiter à part, cependant, nous craignons que le même schéma se répète ensuite sur Lyon, puis Lille, puis Marseille, etc etc.

Nous choisissons donc de nous arrêter la pour cette hypothèse, qui serait difficile à confirmer à 100% sans une donnée mieux répartie.

1.0.7 PB 1 Hypothèse 1

A peu près la même chose que l'hypothèse 2, mais cette fois ci avec l'ajout d'une dimension temporelle (pour identifier un problème ponctuel).

La donnée sera donc visualisée à l'aide d'un graph en 3 dimensions.

[101]:
```
COLUMNS_OF_INTEREST = ["Synthese_eval_sanit", "geores", "Libelle_commune",␣
↪"Date_inspection"]

df = data[COLUMNS_OF_INTEREST].dropna()
df[['lat', 'lng']] = df['geores'].str.split(', ', expand=True).astype(float)
df = df.drop('geores', axis=1)
df = df[(df['Synthese_eval_sanit'] == 'A améliorer') |␣
↪(df['Synthese_eval_sanit'] == 'A corriger de manière urgente')]
df = df[df['lat'] > 30]
label_encoder = LabelEncoder()
df['Libelle_commune'] = label_encoder.fit_transform(df['Libelle_commune'])
df['Date_inspection'] = df['Date_inspection'].apply(lambda x: datetime.
↪fromisoformat(x).timestamp())
df.describe()
```

[101]:

	Libelle_commune	Date_inspection	lat	lng
count	1940.000000	1.940000e+03	1940.000000	1940.000000
mean	597.109278	1.681647e+09	47.293139	2.527574
std	327.342837	7.901530e+06	2.193290	2.272321
min	0.000000	1.662941e+09	41.938073	-4.759437
25%	311.750000	1.676333e+09	45.450000	1.615195
50%	655.000000	1.684109e+09	48.334387	2.351357
75%	844.250000	1.687997e+09	48.885000	3.583333
max	1156.000000	1.692230e+09	50.961239	9.465493

[102]:
```
# CREATE 3D GRAPH
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')

ax.scatter(df['lng'], df['Date_inspection'], df['lat'], c='b', marker='o', s=1)

ax.set_xlabel('Longitude')
ax.set_ylabel('Temps')
ax.set_zlabel('Lattitude')

plt.title('Scatter Plot en 3D')

plt.show()
```

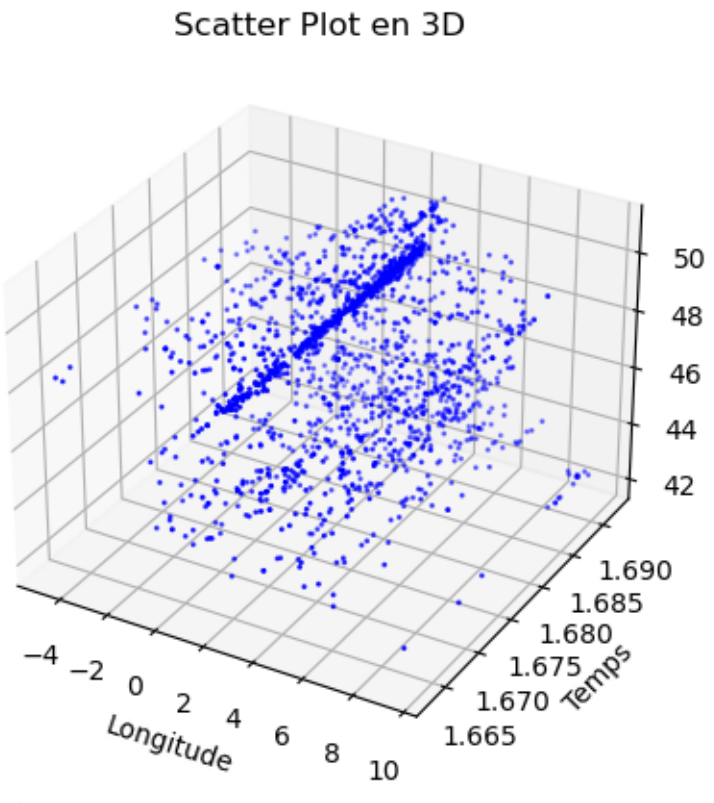

Définition du modèle : 400 clusters, 8 entrées insatisfaisantes pour être considéré comme anormal

[103]:
```
k = 400

kmeans = KMeans(n_clusters=k)

kmeans.fit(df[['lat', 'lng', 'Date_inspection']])

labels = kmeans.labels_

df['Cluster'] = labels

df.head()
```

```
/opt/conda/lib/python3.10/site-packages/sklearn/cluster/_kmeans.py:870:
FutureWarning: The default value of `n_init` will change from 10 to 'auto' in
1.4. Set the value of `n_init` explicitly to suppress the warning
  warnings.warn(
```

[103]:

	Synthese_eval_sanit	Libelle_commune	Date_inspection	lat	lng	\
4	A améliorer	878	1.678234e+09	48.844091	2.219818	

```
6          A améliorer              451     1.675728e+09  48.448928 -4.249809
19         A améliorer              881     1.664150e+09  47.807466  1.078596
20         A améliorer             1066     1.685491e+09  45.057360  5.770684
21         A améliorer             1061     1.674518e+09  48.794437  2.155045

    Cluster
4       382
6       359
19      233
20       26
21      251
```

[104]:
```
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')

ax.scatter(df['lng'], df['Date_inspection'], df['lat'], c=labels,␣
 ↪cmap='viridis', marker='o', s=1)

ax.set_xlabel('Longitude')
ax.set_ylabel('Temps')
ax.set_zlabel('Lattitude')

plt.title('Scatter Plot en 3D')

plt.show()
```

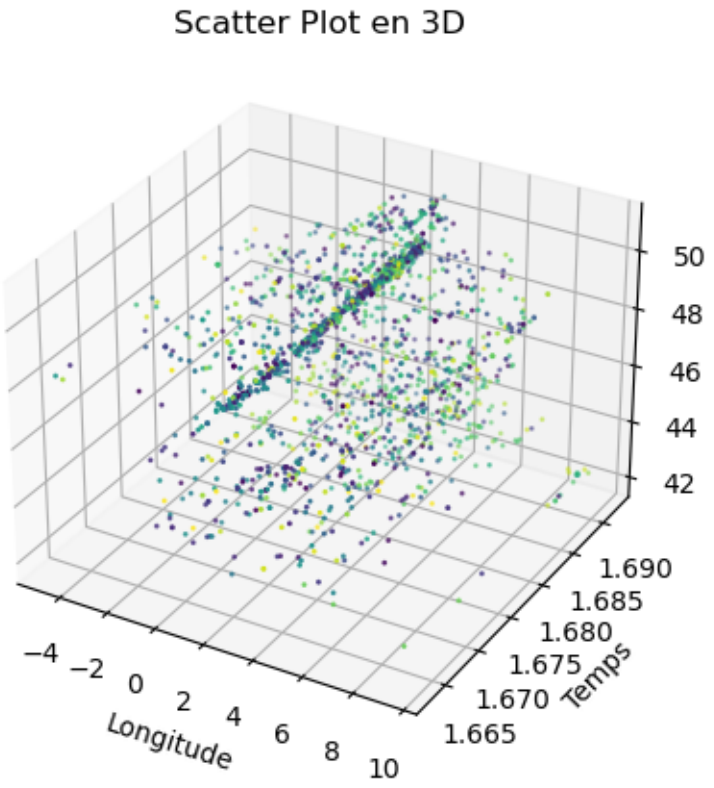

[105]:
```
clusters = df.groupby('Cluster').count()[df.groupby('Cluster').count()['lat'] >
↪8].index.tolist()
len(clusters)
```

[105]: 49

[107]:
```
def set_size(row):
    if row['Cluster'] in clusters:
        return 20
    else:
        return 1

def set_color(row):
    if row['Cluster'] in clusters:
        return row['Cluster']
    else:
        return 0

df['Size'] = df.apply(set_size, axis=1)
df['Color'] = df.apply(set_color, axis=1)
```

```
fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')

ax.scatter(df['lng'], df['Date_inspection'], df['lat'], c=df['Color'],␣
 ↪marker='o', s=df['Size'])

ax.set_xlabel('Longitude')
ax.set_ylabel('Temps')
ax.set_zlabel('Lattitude')

plt.title('Scatter Plot en 3D')

plt.show()
```

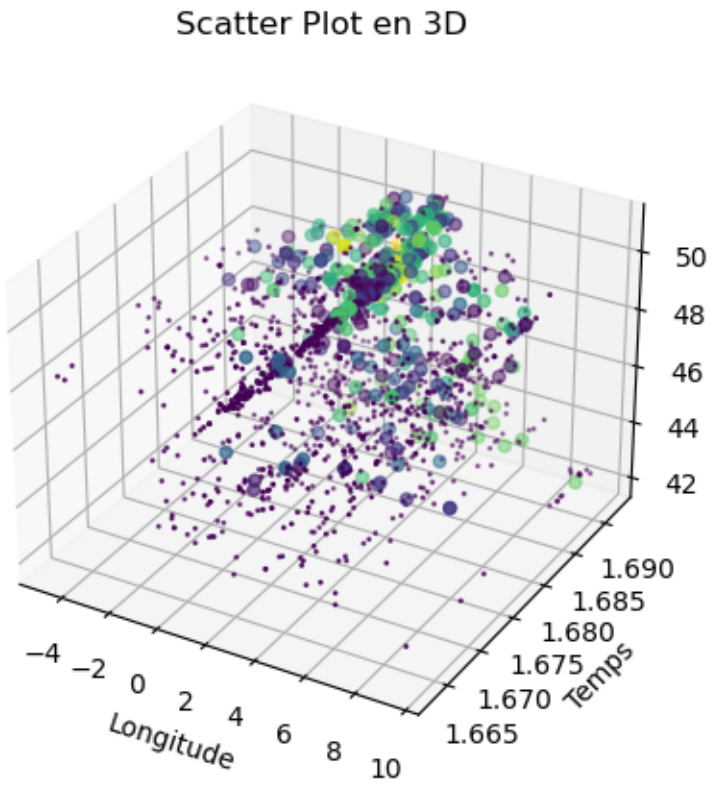

On remarque alors qu'un grand nombre de clusters semblent apparaitre vers les entrées les plus récentes. Deux conclusions possibles : - La situation sanitaire s'est lourdement dégradée ces derniers temps - Le nombres d'inspections sanitaires à augmentée récemment.

Puisque nos donneés ne couvrent qu'une période de deux ans, nous penchons vers la seconde conclusion. Cependant, avec plus de données, il est fort probable que nous puissons valider la premiere conclusion également, et donc notre modèle.